

性选择偏好的形成机制：费希尔过程的前置条件与生物建模

1 问题的提出：从“同性恋基因”到偏好权重

关于人类性取向的讨论中，经常会出现“同性恋基因”这样的说法。这个表述在传播上很直观，但从生物建模角度看，它过于粗糙。因为它把一个复杂的、多层级的行为与身份现象，压缩成了一个基因对一个社会标签的直接决定关系。更合理的问题不是“是否存在一个决定同性恋的基因”，而是：遗传因素是否可能影响个体对某些性状线索的偏好权重？这些偏好权重又如何在现实群体的性别化性状分布中表现为对某些对象类别的吸引？

换句话说，可遗传的未必是“同性恋”或“异性恋”这种最终分类结果，而可能是更底层的参数：对声音、体态、气质、面部结构、行为风格、亲密线索、社会信号等特征的感知敏感性和奖赏反应。由于这些性状在不同性别中的统计分布并不均匀，某一组偏好权重在实际世界中就可能表现为对某一性别更集中的吸引。这样一来，“取向”就不再被理解成一个简单开关，而是一个由生物、发育、经验和文化共同生成的函数结果。

这个改写有两个意义。第一，它避免了单基因决定论。现代遗传学研究通常认为，复杂行为不太可能由单一基因直接决定。以同性交往行为的大规模全基因组关联研究为例，Ganna 等人的研究发现，该行为具有多基因关联，但单个位点效应很小，且无法据此对个体进行有效预测。这说明“同性恋基因”作为单一实体并不成立，更合理的说法是多基因、小效应、环境共同作用。第二，这一改写把问题从身份判断转化为偏好生成机制：生命系统如何把某些性状标记为更有吸引力？这种赋值机制如何受到遗传、神经发育、经验学习和文化环境影响？

因此，本文的任务不是讨论某种取向是否“正常”或“异常”，也不是试图预测、矫正或评价个体取向，而是把性选择偏好当作一个生物建模问题：偏好如何形成，如何影响选择，选择又如何反馈到群体性状分布之中。

2 费希尔过程：偏好与性状的正反馈结构

性选择理论中，费希尔过程¹提供了一个重要参照。它关注的不是普通自然选择意义上的生存优势，而是配偶选择中的偏好如何改变性状分布。若某一性状被偏好者选择得更多，那么拥有该性状的个体获得更高的繁殖机会；如果偏好本身也能在群体中稳定传递，那么偏好和性状便可能形成正反馈。

经典结构可以概括为：

$$\text{偏好 } p \longrightarrow \text{性状 } x \text{ 获得选择优势} \longrightarrow x \text{ 的频率上升} \longrightarrow p \text{ 得到强化.} \quad (1)$$

但是，本文关心的是费希尔过程之前的一个更基础问题：偏好函数本身从何而来？在经典性选择模型中，通常已经预设了某种偏好存在，例如对颜色、鸣叫、体型或装饰性状的偏好。但在人类复杂偏好中，偏好并不是单一变量，而更像一个多维权重系统。因此，费希尔过程的前置条件可以写成：

1. 群体中存在可比较的性状差异；
2. 个体之间存在偏好权重差异；
3. 偏好会影响选择概率；
4. 选择概率会影响性状的群体分布；
5. 偏好本身具有一定稳定性，可能来自遗传、发育、学习或文化复制；
6. 偏好与性状之间可以形成统计相关或反馈循环。

本文所说的“推广”，正是从第 2 条开始：不把偏好看作一个已给定的简单变量，而是把它拆成一个可建模的权重向量。

3 个体层模型：把偏好表示为赋值函数

设一个潜在吸引对象具有 n 个可被感知的性状维度：

$$\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n. \quad (2)$$

¹费希尔过程，通常也称 Fisherian runaway 或 Fisherian runaway sexual selection，指偏好与被偏好性状之间可能形成自我强化的性选择反馈。经典例子是：如果雌性对某种雄性装饰性状存在偏好，那么具有该性状的雄性会获得更高的配偶机会；若偏好本身也有遗传基础，雌性后代可能继承偏好，雄性后代可能继承被偏好的性状，于是偏好与性状在群体中形成遗传相关并共同扩张。该过程并不意味着性状会无限增长，现实中会受到自然选择成本、配偶选择成本、群体结构和环境约束的限制，最终可能达到平衡，也可能出现周期性变化或被其他选择压力打断。本文使用“费希尔过程”主要是借用其“偏好—性状—反馈”的结构，而不是把人类复杂偏好直接等同于某个动物装饰性状模型。

这些维度可以是视觉、听觉、嗅觉、行为风格、情绪互动、社会线索等。个体的偏好权重表示为：

$$\mathbf{p} = (p_1, p_2, \dots, p_n)^T \in \mathbb{R}^n. \quad (3)$$

其中 p_i 表示个体对第 i 类性状的赋值强度。则对象的吸引强度可以写成线性近似：

$$A(\mathbf{x}) = \mathbf{p}^T \mathbf{x} = \sum_{i=1}^n p_i x_i. \quad (4)$$

这个公式不是说真实偏好一定是线性的，而是给出一个最小模型。它的含义是：偏好不是一个神秘标签，而是个体神经系统对外界特征进行加权赋值的结果。若 p_i 较大，则第 i 类特征更容易被注意、记忆并进入奖赏系统；若 p_i 接近零，则该特征对吸引评分影响较小；若 $p_i < 0$ ，则该特征可能产生回避倾向。

在更复杂的情况下，吸引函数可以加入非线性项：

$$A(\mathbf{x}) = \mathbf{p}^T \mathbf{x} + \frac{1}{2} \mathbf{x}^T Q \mathbf{x} + b + \varepsilon. \quad (5)$$

其中 Q 表示性状之间的交互项， b 是基础偏置， ε 是无法观测的随机扰动。例如某一特征单独存在时影响不大，但与另一特征同时出现时会显著增强吸引，这就可以由 Q 的非对角元素表示。

在这一框架下，“取向”不是一个先验类别，而是偏好函数在现实对象集合上的输出分布。也就是说，一个人最终被哪些对象吸引，取决于 $\mathbf{p}$ 如何作用于现实群体中的 $\mathbf{x}$ 。

4 选择概率模型：从吸引评分到行为倾向

现实选择并不是完全确定的。即使某个对象的吸引评分较高，个体也不一定必然选择它，因为还存在机会、距离、社会限制、关系结构、随机性和文化压力。因此，需要把吸引评分转化为概率。一个常用的形式是 softmax 模型：

$$\Pr(i) = \frac{\exp(\beta A(\mathbf{x}_i))}{\sum_{j=1}^m \exp(\beta A(\mathbf{x}_j))}. \quad (6)$$

其中 m 是可选择对象数量， $\Pr(i)$ 是选择第 i 个对象的概率， β 是选择强度参数。

当 $\beta \rightarrow 0$ 时，所有对象被选择的概率趋于平均，说明偏好对选择几乎不起作用：

$$\Pr(i) \approx \frac{1}{m}. \quad (7)$$

当 $\beta \rightarrow \infty$ 时，模型趋向于选择吸引评分最高的对象：

$$\Pr(i) \rightarrow \begin{cases} 1, & i = \arg \max_j A(\mathbf{x}_j), \\ 0, & \text{otherwise.} \end{cases} \quad (8)$$

这个参数具有明确的生物学解释： β 越大，说明偏好越强、选择越集中； β 越小，说明选择越受随机性、社会环境或机会结构影响。由此可见，偏好权重 $\mathbf{p}$ 决定“什么被赋予吸引力”，而 β 决定“这种吸引力在多大程度上转化为实际选择”。

如果加入文化、规训和身份解释，可以把选择概率进一步写成：

$$\Pr(i) = \frac{\exp(\beta A(\mathbf{x}_i) - C_i + R_i)}{\sum_{j=1}^m \exp(\beta A(\mathbf{x}_j) - C_j + R_j)}. \quad (9)$$

其中 C_i 表示文化惩罚、社会成本或表达抑制， R_i 表示文化奖励、身份支持或社会可见性。这个形式说明：文化环境未必直接制造底层偏好，但会显著改变偏好的表达、解释和实际选择概率。

5 从特征偏好到性别集中：性别不是唯一原子变量

本文的关键命题是：可遗传或可稳定传递的未必是对“某一性别”的直接选择，而可能是对若干性状维度的赋值倾向。性别在模型中可以被看作一种宏观标签，但具体吸引往往通过许多性状线索实现。

设性别标签为 $S \in \{M, F\}$ ，对象特征在不同性别条件下服从不同分布：

$$\mathbf{x} \mid S = M \sim D_M, \quad \mathbf{x} \mid S = F \sim D_F. \quad (10)$$

那么个体对某一性别的总体吸引，不是由 S 这个标签单独决定，而是由该性别对应的性状分布与偏好权重共同决定。若使用指数选择模型，则选择性别 S 的相对概率可写为：

$$\Pr(S = s) = \frac{N_s \mathbb{E}_{\mathbf{x} \sim D_s} [\exp(\beta \mathbf{p}^\top \mathbf{x})]}{\sum_{s' \in \{M, F\}} N_{s'} \mathbb{E}_{\mathbf{x} \sim D_{s'}} [\exp(\beta \mathbf{p}^\top \mathbf{x})]}. \quad (11)$$

其中 N_s 表示可接触到的该类对象规模。这个式子说明，对某一性别的集中吸引可以从两个方面产生：第一，偏好权重 $\mathbf{p}$ 更匹配该性别中更常见的性状组合；第二，环境中该类对象的可见度、接触机会和社会表达条件不同。

为了进一步推导，假设不同性别条件下性状服从多元正态分布：

$$\mathbf{x} \mid S = s \sim \mathcal{N}(\boldsymbol{\mu}_s, \boldsymbol{\Sigma}_s). \quad (12)$$

则利用正态分布矩母函数可得：

$$\mathbb{E} [\exp (\beta \mathbf{p}^{\top} \mathbf{x})] = \exp \left(\beta \mathbf{p}^{\top} \boldsymbol{\mu}_s + \frac{\beta^2}{2} \mathbf{p}^{\top} \Sigma_s \mathbf{p} \right). \quad (13)$$

于是选择 M 而非 F 的对数优势为：

$$\log \frac{\Pr(S = M)}{\Pr(S = F)} = \log \frac{N_M}{N_F} + \beta \mathbf{p}^{\top} (\boldsymbol{\mu}_M - \boldsymbol{\mu}_F) \quad (14)$$

$$+ \frac{\beta^2}{2} \mathbf{p}^{\top} (\Sigma_M - \Sigma_F) \mathbf{p}. \quad (15)$$

这个公式非常关键。它说明“偏向某一性别”并不必然来自一个直接编码性别对象的单一变量，而可以来自三类因素的合成：

1. $\log(N_M/N_F)$ ：可接触对象数量与社会可见性差异；
2. $\mathbf{p}^{\top}(\boldsymbol{\mu}_M - \boldsymbol{\mu}_F)$ ：偏好权重与两类对象平均性状差异的匹配程度；
3. $\mathbf{p}^{\top}(\Sigma_M - \Sigma_F)\mathbf{p}$ ：性状多样性差异对偏好输出的影响。

因此，“同性恋基因”问题可以被转写为一个更细的命题：某些遗传或发育因素可能改变 $\mathbf{p}$ ，而 $\mathbf{p}$ 与 D_M, D_F 的关系决定吸引输出在性别标签上的集中程度。遗传因素没有必要直接编码“喜欢男性”或“喜欢女性”；它可以只改变对某些特征维度的敏感性，最终由现实分布将其表现为某种取向结构。

6 偏好权重的来源：遗传、发育、学习与文化

现在需要解释 $\mathbf{p}$ 从何而来。本文将其分解为四个部分：

$$\mathbf{p} = B\mathbf{g} + \mathbf{d} + \mathbf{l} + \mathbf{c} + \boldsymbol{\eta}. \quad (16)$$

其中：

- $\mathbf{g}$ 表示多基因背景；
- B 表示基因背景到偏好维度的映射矩阵；
- $\mathbf{d}$ 表示发育过程，包括激素环境、神经发育差异等；
- $\mathbf{l}$ 表示个体经验、奖赏学习和记忆；
- $\mathbf{c}$ 表示文化表征、教育、奖励、规训、身份叙事与社会可见性；
- $\boldsymbol{\eta}$ 表示随机扰动和未观测因素。

这个分解的意义在于，它允许我们同时承认生物因素与文化因素，而不是落入“基因决定”或“文化决定”的二分。遗传因素可能影响某些底层敏感性，但最终偏好仍然要经过发育、经验和社会解释。文化环境可能不直接改写最底层的感知敏感性，却能强烈影响偏好的命名、压抑、奖励、表达和身份化。

为了描述偏好随经验变化，可以引入简单的学习方程：

$$\mathbf{p}_{t+1} = \mathbf{p}_t + \alpha r_t \mathbf{x}_t - \lambda \mathbf{p}_t + \mathbf{u}_t. \quad (17)$$

其中 r_t 是第 t 次经验带来的奖赏信号， α 是学习率， λ 是遗忘或正则化系数， $\mathbf{u}_t$ 是文化输入、语言解释或社会反馈。若某类特征 $\mathbf{x}_t$ 经常与正奖赏 $r_t > 0$ 相伴，则对应方向上的偏好权重会增强；若经常与惩罚、羞耻或风险相伴，则其表达可能受到抑制。

不过，这里必须区分“底层吸引”与“表达行为”。文化和教育可以显著影响一个人如何理解、命名、表达或隐藏自己的偏好，但这不等于可以任意制造或矫正底层取向。更准确的说法是：文化环境参与偏好系统的可见化与叙事化，而不是简单地像开关一样决定取向。

7 群体反馈：从个体偏好到性状分布

费希尔过程的核心在于反馈。为了描述群体层面的变化，设第 t 代群体中特征分布为 $D_t(\mathbf{x})$ ，具有特征 $\mathbf{x}$ 的个体在选择中获得的相对适合度为 $W_t(\mathbf{x})$ ，则下一代分布可写成：

$$D_{t+1}(\mathbf{x}) = \frac{D_t(\mathbf{x})W_t(\mathbf{x})}{\int D_t(\mathbf{z})W_t(\mathbf{z})d\mathbf{z}}. \quad (18)$$

其中分母是归一化因子，保证分布总和为 1。

如果某类性状更容易被偏好系统选择，可以令：

$$W_t(\mathbf{x}) = W_0(\mathbf{x}) \exp(\rho \bar{\mathbf{p}}_t^\top \mathbf{x} - K(\mathbf{x})). \quad (19)$$

其中 $W_0(\mathbf{x})$ 是基础生存适合度， ρ 是性选择强度， $\bar{\mathbf{p}}_t$ 是群体平均偏好， $K(\mathbf{x})$ 是性状成本。该式表示：性状一方面可能因被偏好而提高选择优势，另一方面也可能因生存成本而受到抑制。

若群体平均性状为

$$\bar{\mathbf{x}}_t = \int \mathbf{x} D_t(\mathbf{x}) d\mathbf{x}, \quad (20)$$

则在弱选择近似下，平均性状的变化方向可近似写成：

$$\Delta \bar{\mathbf{x}}_t \propto \text{Cov}_{D_t}(\mathbf{x}, \log W_t(\mathbf{x})). \quad (21)$$

若忽略成本项，代入 $\log W_t(\mathbf{x}) \approx \rho \bar{\mathbf{p}}_t^\top \mathbf{x}$ ，可得：

$$\Delta \bar{\mathbf{x}}_t \propto \rho \Sigma_{x,t} \bar{\mathbf{p}}_t. \quad (22)$$

其中 $\Sigma_{x,t}$ 是群体性状协方差矩阵。这个结果表明，性状均值会沿着群体偏好权重指向的方向移动，但移动速度受到性状变异量影响。没有性状差异，就没有可供选择放大的方向。

偏好本身也可以在群体中变化。设平均偏好为 $\bar{\mathbf{p}}_t$ ，则：

$$\bar{\mathbf{p}}_{t+1} = (1 - \mu) \bar{\mathbf{p}}_t + h_p^2 \text{Cov}(\mathbf{p}, R) + \gamma \Delta \mathbf{c}_t + \boldsymbol{\xi}_t. \quad (23)$$

其中 μ 表示偏好漂变或代际衰减， h_p^2 表示偏好权重的广义遗传度， R 表示繁殖或社会传播收益， $\gamma \Delta \mathbf{c}_t$ 表示文化环境变化造成的偏好表达变化， $\boldsymbol{\xi}_t$ 是随机扰动。

这就形成了一个扩展版反馈结构：

$$\bar{\mathbf{p}}_t \longrightarrow W_t(\mathbf{x}) \longrightarrow D_{t+1}(\mathbf{x}) \longrightarrow \text{经验暴露与社会表征} \longrightarrow \bar{\mathbf{p}}_{t+1}. \quad (24)$$

在动物性选择中，这个回路可能主要通过繁殖成功率实现；在人类社会中，它还会被文化传播、媒体表征、制度限制、身份叙事和技术环境重写。因此，人类偏好模型不应被简化为纯遗传费希尔过程，而应被视为生物—文化混合反馈系统。

8 模型解释：为什么“同性恋基因”不是好问题

根据以上模型，“同性恋基因”之所以不是好问题，是因为它把输出结果误认为输入变量。若取向是偏好权重作用于现实性状分布后的结果，那么基因即使参与其中，也更可能作用于底层参数，而不是直接编码身份标签。

可以把这一点写成层级关系：

$$\text{基因与发育} \longrightarrow \text{神经偏好权重} \longrightarrow \text{特征赋值} \longrightarrow \text{对象吸引} \longrightarrow \text{身份与行为表达}. \quad (25)$$

在这一链条中，每一层都可能被不同因素影响。基因和发育主要影响较底层的神经敏感性与奖赏阈值；经验学习影响哪些线索被强化；文化环境影响哪些吸引被允许承认、哪些被压抑、哪些被组织成身份叙事；社会结构则影响实际选择是否能够表达出来。

因此，较准确的表述不是“同性恋基因可遗传”，而是：

某些影响偏好权重、感知敏感性、奖赏反应和社会行为倾向的生物因素可能具有部分遗传基础；这些因素与发育、经验、文化环境和对象性状分布共同作用，最终形成不同的取向表现。

这个说法保留了生物学因素，又避免把复杂取向还原为单个基因。它也能解释为什

么相关研究会同时发现遗传因素与环境因素：因为二者并不是互斥解释，而是在不同层级共同参与偏好函数的形成。

9 结论

本文将“同性恋基因”这一流行说法改写为“性选择偏好权重是否具有部分可遗传性”的建模问题。其核心判断是：可遗传的未必是完整取向标签，而可能是对某些性状线索的感知敏感性、奖赏阈值和选择权重。由于这些性状在现实群体中的分布具有性别差异，偏好权重在对象分布上的投影结果，可能表现为对某一性别更集中的吸引。

费希尔过程为这一问题提供了重要参照。它说明偏好与被偏好性状之间可能形成正反馈，但在本文中，费希尔过程不是被直接套用于人类取向，而是作为“偏好—性状—反馈”结构的理论原型。真正需要建模的是费希尔过程的前置条件：偏好函数如何形成，如何作用于对象性状分布，又如何在生物、经验和文化环境中被强化或抑制。

从公式上看，偏好可以表示为 $A(\mathbf{x}) = \mathbf{p}^\top \mathbf{x}$ ，选择可以表示为 softmax 概率，性别集中可以由 $\mathbf{p}$ 与不同性别性状分布 D_M, D_F 的关系推出，群体反馈则可以用 $D_{t+1}(\mathbf{x}) \propto D_t(\mathbf{x})W_t(\mathbf{x})$ 表示。由此可见，取向不是一个简单基因开关，而是一个复杂的生物—文化动力系统。

因此，这一模型的意义并不在于给出某种最终答案，而在于改变提问方式：不要问“是否存在同性恋基因”，而应问“生物体如何形成对性状的偏好权重，这些权重又如何在群体分布和文化环境中表现为具体取向”。这个问题更精确，也更适合被生物学、神经科学和自动化建模方法共同处理。